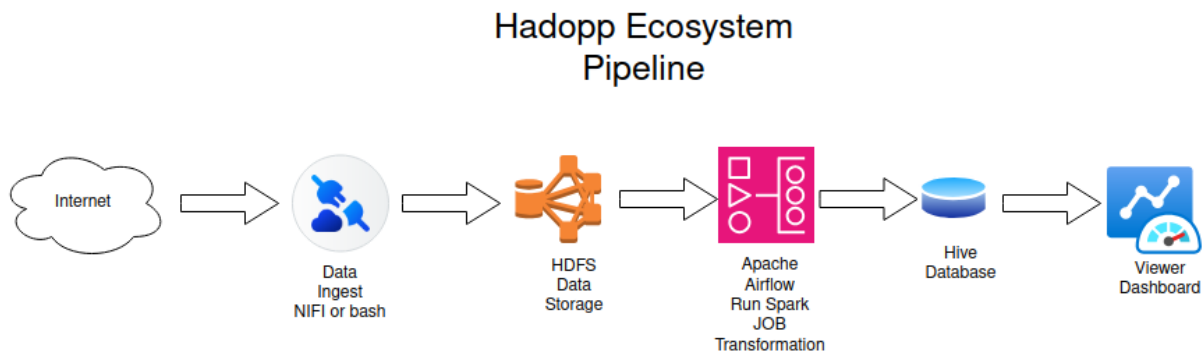


ESCUADERO
BOOTCAM DATA ENGINEERING
EXAMEN FINAL
REV 12-01-25

EJ. 2 Rent a Car

Se realizó un análisis con herramientas open source del ecosistema Hadoop, con una arquitectura como la siguientes



1) INGESTA DE DATA

CREAMOS UN DIRECTORIO EN HDFS PARA INGESTAR LOS ARCHIVOS DE ANÁLISIS

```
hdfs dfs -mkdir /ingest
```

```
hdfs dfs -mkdir /ingest4
```

2) cargamos los datos

<https://dataengineerpublic.blob.core.windows.net/data-engineer/CarRentalData.csv>

<https://dataengineerpublic.blob.core.windows.net/data-engineer/georef-united-states-of-america-state.csv>

```
wget -P ruta_destino -O ruta_destino/nombre_archivo.csv ruta_al_archivo
```

```
wget -P ./ "https://dataengineerpublic.blob.core.windows.net/data-engineer/CarRentalData.csv"
```

```
wget -O ./georef_usa.csv "https://dataengineerpublic.blob.core.windows.net/data-engineer/georef-united-states-of-america-state.csv"
```

Ingesta completada

```

hadoop@4236fd64627:~$ wget -P / "https://dataengineerpublic.blob.core.windows.net/data-engineer/CarRentalData.csv"
--2024-12-18 15:14:17-- https://dataengineerpublic.blob.core.windows.net/data-engineer/CarRentalData.csv
Resolving dataengineerpublic.blob.core.windows.net (dataengineerpublic.blob.core.windows.net)... 20.150.25.164
Connecting to dataengineerpublic.blob.core.windows.net (dataengineerpublic.blob.core.windows.net)|20.150.25.164|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 533157 (521K) [text/csv]
Saving to: './CarRentalData.csv'

CarRentalData.csv                               100%[=====] 520.66K  436KB/s   in 1.2s

2024-12-18 15:14:19 (436 KB/s) - './CarRentalData.csv' saved [533157/533157]

hadoop@4236fd64627:~$ wget -O ./georef_usa.csv "https://dataengineerpublic.blob.core.windows.net/data-engineer/CarRentalData.csv"
--2024-12-18 15:14:34-- https://dataengineerpublic.blob.core.windows.net/data-engineer/CarRentalData.csv
Resolving dataengineerpublic.blob.core.windows.net (dataengineerpublic.blob.core.windows.net)... 20.150.25.164
Connecting to dataengineerpublic.blob.core.windows.net (dataengineerpublic.blob.core.windows.net)|20.150.25.164|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 533157 (521K) [text/csv]
Saving to: './georef_usa.csv'

./georef_usa.csv                               100%[=====] 520.66K  364KB/s   in 1.4s

2024-12-18 15:14:36 (364 KB/s) - './georef_usa.csv' saved [533157/533157]

hadoop@4236fd64627:~$

```

Subimos los archivos a HDFS

```

hdfs dfs -put CarRentalData.csv /ingest
hdfs dfs -put georef_usa.csv /ingest

```

Verificamos si los datos están

```
hdfs dfs -ls /ingest/
```

Tenemos los archivos cargados

```

hadoop@d5e109c82f52:~$ hdfs dfs -ls /ingest/
Found 2 items
-rw-r--r-- 1 hadoop supergroup 533157 2025-01-11 10:08 /ingest/CarRentalData.csv
-rw-r--r-- 1 hadoop supergroup 533157 2025-01-11 10:08 /ingest/georef_usa.csv
hadoop@d5e109c82f52:~$

```

Para la automatización realizamos un script de ingesta con un archivo `.sh`

Creamos el script por consola en un `.sh`

```
#!/bin/bash
```

```
# Mensaje de inicio
```

```
echo "***** Inicio Ingesta Rent a Car *****"
```

```
# Directorio landing en hadoop
```

```
LANDING_DIR="/home/hadoop/landing"
```

```
# Directorio destino en HDFS
```

```
DEST_DIR="/ingest"
```

```
# Nombre archivos
```

```
rentacar="CarRentalData.csv"
```

```
georef="georef_usa.csv" georef-united-states-of-america-state.csv"
```

```
# Descarga archivos
```

```
wget -P $LANDING_DIR -O $LANDING_DIR/$rentacar
```

```
"https://dataengineerpublic.blob.core.windows.net/data-engineer/CarRentalData.csv"
```

```
wget -P $LANDING_DIR -O $LANDING_DIR/$georef
```

```
"https://dataengineerpublic.blob.core.windows.net/data-engineer/georef-united-states-of-america-state.csv"
```

```
# Mover archivos a HDFS
hdfs dfs -put $LANDING_DIR/$rentacar $DEST_DIR
hdfs dfs -put $LANDING_DIR/$georef $DEST_DIR
```

```
# Remueve archivos, asegurando que el archivo existe
rm -f $LANDING_DIR/$rentacar
rm -f $LANDING_DIR/$georef
```

```
# Mensaje de finalización
echo "\n***** Fin Ingesta rent a car *****"
```

```
nano /home/hadoop/scripts/ingest_car.sh
```

y debemos darle permiso de ejecución

```
chmod +x /home/hadoop/scripts/rev_ingest_car.sh.sh
```

lo ejecutamos para verificar el funcionamiento y chequeemos la carga de los datos

```
bash /home/hadoop/scripts/ingest_car.sh
```

el bash está funcionando

```
hadoop@ds109c82f52:~/scripts$ chmod +x ingest_car.sh
hadoop@ds109c82f52:~/scripts$ bash /home/hadoop/scripts/ingest_car.sh
***** Inicio Ingesta Rent a Car *****
--2025-01-05 11:42:34-- https://dataengineerpublic.blob.core.windows.net/data-engineer/CarRentalData.csv
Resolving dataengineerpublic.blob.core.windows.net (dataengineerpublic.blob.core.windows.net)... 20.150.25.164
Connecting to dataengineerpublic.blob.core.windows.net (dataengineerpublic.blob.core.windows.net)|20.150.25.164|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 533157 (521K) [text/csv]
Saving to: '/home/hadoop/Landing/CarRentalData.csv'

CarRentalData.csv      100%[=====] 520.66K  410KB/s   in 1.3s
2025-01-05 11:42:36 (410 KB/s) - '/home/hadoop/Landing/CarRentalData.csv' saved [533157/533157]

--2025-01-05 11:42:36-- https://dataengineerpublic.blob.core.windows.net/data-engineer/georef-united-states-of-america-state.csv
Resolving dataengineerpublic.blob.core.windows.net (dataengineerpublic.blob.core.windows.net)... 20.150.25.164
Connecting to dataengineerpublic.blob.core.windows.net (dataengineerpublic.blob.core.windows.net)|20.150.25.164|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 3380726 (3.2M) [text/csv]
Saving to: '/home/hadoop/Landing/georef-united-states-of-america-state.csv'

georef-united-states-of-america-state.csv  100%[=====] 3.22M  946KB/s   in 3.5s
2025-01-05 11:42:41 (946 KB/s) - '/home/hadoop/Landing/georef-united-states-of-america-state.csv' saved [3380726/3380726]

put: '/ing': File exists
\n***** Fin Ingesta rent a car *****
hadoop@ds109c82f52:~/scripts$
```

y cargado los archivos en HDFS y le damos los permisos

Damos los permisos necesarios de los archivos

```
hdfs dfs -chmod 644 /ingest4/*.csv
```

y del directorios

```
hdfs dfs -chmod 755 /ingest4
```

```
hadoop@ds109c82f52:~/scripts$ hdfs dfs -ls /ingest
Found 6 items
-rw-r--r-- 1 hadoop supergroup 533157 2025-01-05 11:47 /ingest/CarRentalData.csv
-rw-r--r-- 1 hadoop supergroup 3380726 2025-01-05 11:47 /ingest/georef-united-states-of-america-state.csv
-rwxr-xr-x 1 hadoop supergroup 14334074 2025-01-02 06:40 /ingest/part-00000-6a6df198-426c-4de1-93fb-ca9329563b7e-c000
-rwxr-xr-x 1 hadoop supergroup 10864128 2025-01-02 06:40 /ingest/part-00001-6a6df198-426c-4de1-93fb-ca9329563b7e-c000
-rwxr-xr-x 1 hadoop supergroup 9938312 2025-01-02 06:40 /ingest/part-00002-6a6df198-426c-4de1-93fb-ca9329563b7e-c000
-rwxr-xr-x 1 hadoop supergroup 6885510 2025-01-02 06:40 /ingest/part-00003-6a6df198-426c-4de1-93fb-ca9329563b7e-c000
```

3.- Armamos las tablas en Hive:

Crear en hive una database `car_rental_db` y dentro una tabla llamada `car_rental_analytics`, con estos campos:

campos	tipo
fuelType	string

rating	integer
renterTripsTaken	integer
reviewCount	integer
city	string
state_name	string
owner_id	integer
rate_daily	integer
make	string
model	string
year	integer

-

Pasos previos

show databases;

con esto vemos que tenemos

creamos una nueva data base

```
-- create database car_rental_db;
```

le indico en que DB voy a trabajar

```
-- use car_rental_db;
```

para saber donde estamos parados

```
-- select current_database();
```

Creamos la tabla car_rental_analytics,

```
CREATE EXTERNAL TABLE car_rental_analytics (  
  fuelType STRING,  
  rating INTEGER,  
  renterTripsTaken INTEGER,  
  reviewCount INTEGER,  
  city STRING,  
  state_name STRING,  
  rate_daily INTEGER,  
  make STRING,  
  model STRING,  
  year INTEGER  
)  
ROW FORMAT DELIMITED  
FIELDS TERMINATED BY ','  
STORED AS TEXTFILE  
LOCATION '/ingest';
```

-

-
Ç

```
hive> show databases;  
OK  
car_rental_db  
default  
tripdata  
vuelosdb  
Time taken: 0.369 seconds, Fetched: 4 row(s)  
hive> use car_rental_db;  
OK  
Time taken: 0.02 seconds  
hive> CREATE EXTERNAL TABLE car_rental_analytics (  
  > fuelType STRING,  
  > tipo STRING,  
  > rating INTEGER,  
  > renterTripsTaken INTEGER,  
  > reviewCount INTEGER,  
  > city STRING,  
  > state_name STRING,  
  > rate_daily INTEGER,  
  > make STRING,  
  > model STRING,  
  > year INTEGER  
  > )  
  > ROW FORMAT DELIMITED  
  > FIELDS TERMINATED BY ','  
  > STORED AS TEXTFILE  
  > LOCATION '/ingest';  
OK  
Time taken: 0.093 seconds  
hive> show tables;  
OK  
car_rental_analytics  
Time taken: 0.025 seconds, Fetched: 1 row(s)  
hive> █
```

Tabla creada en HIVE

3.- Transformaciones:

Crear un script para tomar el archivo desde HDFS y hacer las siguientes transformaciones:

En donde sea necesario, modificar los nombres de las columnas. Evitar espacios y puntos (reemplazar por _). Evitar nombres de columna largos

Redondear los float de 'rating' y castear a int.

Joinear ambos files

Eliminar los registros con rating nulo

Cambiar mayúsculas por minúsculas en 'fuelType'

Excluir el estado Texas

Finalmente insertar en Hive el resultado

Script para leer y transformar los datos

```
df_rentacar = spark.read.option("header", "true").option("sep",
",").csv("hdfs://172.17.0.2:9000/ingest/CarRentalData.csv")
```

```
>>> from pyspark.sql import SparkSession
>>> from pyspark.sql.functions import lit
>>> from pyspark.sql import Functions as F
>>> from pyspark.sql.types import FloatType
>>> from pyspark.sql.functions import to_date, col
>>> from pyspark.sql.functions import lit
>>> df_rentacar = spark.read.option("header", "true").option("sep", ",").csv("hdfs://172.17.0.2:9000/ingest/CarRentalData.csv")
>>> df_rentacar.show(5, truncate=False)
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|fuelType|rating|renterTripsTaken|reviewCount|location.city|location.country|location.latitude|location.longitude|location.state|owner.id|rate.daily|vehicle.make|vehicle.model|vehicle.type|vehicle.year|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|ELECTRIC|5|13|12|Seattle|US|47.449107|-122.308841|WA|12847615|135|Tesla|Model X|suv|2019|
|ELECTRIC|5|2|1|Tlajeras|US|35.11106|-106.276551|NM|15621242|190|Tesla|Model X|suv|2018|
|HYBRID|4.92|28|24|Albuquerque|US|35.127163|-106.566681|NM|10199256|35|Toyota|Prius|car|2012|
|GASOLINE|5|121|28|Albuquerque|US|35.149726|-106.711425|NM|9365406|75|Ford|Mustang|car|2018|
|GASOLINE|5|13|1|Albuquerque|US|35.208659|-106.601008|NM|3533565|47|Chrysler|Sebring|car|2010|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
only showing top 5 rows
```

Con el segundo set de datos, hacemos lo mismo

Cargar el archivo CSV en un DataFrame

```
df_georef2 = spark.read.csv("hdfs://172.17.0.2:9000/ingest/georef_usa.csv",
                             header=True,
                             inferSchema=True,
                             sep=";")
```

Mostrar las primeras filas del DataFrame

```
df_georef2.show(10, truncate=False)
```

Ver el esquema del DataFrame para confirmar los tipos de datos

```
df_georef2.printSchema()
```

```
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|Geo Point|Geo Shape|Year|Official Code State|Official Name State|Iso 3166-3 Area Code|Type|United States Postal Service state abbreviation|State FIPS Code|State GNIS Code|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|131.44720010145345...|["coordinates"...]|2022|48|Texas|USA|state|TX|null|1779801|
|38.64257169984573...|["coordinates"...]|2022|54|West Virginia|USA|state|WV|null|1779805|
|18.21570685501268...|["coordinates"...]|2022|72|Puerto Rico|PRI|outlying area|PR|null|1779808|
|40.10998794109383...|["coordinates"...]|2022|34|New Jersey|USA|state|NJ|null|1779795|
|20.99509455589766...|["coordinates"...]|2022|15|Hawaii|USA|state|HI|null|1779782|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
only showing top 5 rows
```

```
>>> df_georef2 = spark.read.csv("hdfs://172.17.0.2:9000/ingest/georef_usa.csv",
...                             header=True,
...                             inferSchema=True,
...                             sep=";")
>>> df_georef2.printSchema()
root
 |-- Geo Point: string (nullable = true)
 |-- Geo Shape: string (nullable = true)
 |-- Year: integer (nullable = true)
 |-- Official Code State: integer (nullable = true)
 |-- Official Name State: string (nullable = true)
 |-- Iso 3166-3 Area Code: string (nullable = true)
 |-- Type: string (nullable = true)
 |-- United States Postal Service state abbreviation: string (nullable = true)
 |-- State FIPS Code: string (nullable = true)
 |-- State GNIS Code: integer (nullable = true)
```

Modificación de columnas

Modificar los nombres de las columnas. Evitar espacios y puntos (reemplazar por _). Evitar nombres de columna largos

Obtenemos las columnas actuales

```
current_columns = df_rentacar.columns
```

Transformamos los nombre de columnas

```
new_columns = [ col.replace('.', '_').replace(' ', '_').lower() if col != 'fuelType' else 'fueltype' for col in current_columns ]
```

```
df_rentacar = df_rentacar.toDF(*new_columns)
```

Mostramos el resultados

```
>>> current_columns = df_rentacar.columns
>>> new_columns = [ col.replace('.', '_').replace(' ', '_').lower() if col != 'fueltype' else 'fueltype' for col in current_columns ]
>>> df_rentacar = df_rentacar.toDF(*new_columns)
>>> df_rentacar.show(5)
```

fueltype	rating	rentertripstaken	reviewcount	location_city	location_country	location_latitude	location_longitude	location_state	owner_id	rate_daily	vehicle_make	vehicle_model	vehicle_type	vehicle_year
ELECTRIC	5	13	12	Seattle	US	47.449107	-122.308841	WA	12847615	135	Tesla	Model X	suv	2019
ELECTRIC	5	21	1	Tijeras	US	35.11106	-106.276551	NM	115621242	190	Tesla	Model X	suv	2018
HYBRID	4.92	28	24	Albuquerque	US	35.127163	-106.566681	NM	10199256	35	Toyota	Prius	car	2012
GASOLINE	5	21	20	Albuquerque	US	35.149726	-106.711425	NM	9365496	75	Ford	Mustang	car	2018
GASOLINE	5	3	1	Albuquerque	US	35.208659	-106.601008	NM	3553565	47	Chrysler	Sebring	car	2010

only showing top 5 rows

hacemos los mismo para el df df_georef2, viendo los dos DF la columna United States Postal Service state abbreviation en el df_georef2 es la misma que la columnas location_state en el df_rentacar la renombramos de la misma forma

Paso 1: Reemplazar espacios " " por guiones bajos "_" en todos los nombres de columnas

```
df_georef2 = df_georef2.toDF(*[col.replace(" ", "_") for col in df_georef2.columns])
```

Paso 2: Renombrar las columnas específicas según lo solicitado

```
df_georef2 = df_georef2.withColumnRenamed("Official_Code_State", "code_state") \
    .withColumnRenamed("Official_Name_State", "name_state") \
```



```

        .withColumnRenamed("United_States_Postal_Service_state_abbreviat
on", "location_state") \
        .withColumnRenamed("Iso_3166-3_Area_Code", "iso_area_code")

```

Paso 3: Borrar la columna "Geo_Shape"

```
df_georef2 = df_georef2.drop("Geo_Shape")
```

Paso 4: Mostrar el DataFrame resultante

```
df_georef2.show(5, truncate=False)
```

Paso 5: Mostrar el esquema del DataFrame actualizado

```
df_georef2.printSchema()
```

Mostramos el resultados

```
df_georef2.show(5)
```

```

>>> df_georef2 = df_georef2.toDF([col.replace(" ", "_") for col in df_georef2.columns])
>>> df_georef2 = df_georef2.withColumnRenamed("Official_Code_State", "code_state") \
...
...     .withColumnRenamed("Official_Name_State", "name_state") \
...     .withColumnRenamed("United_States_Postal_Service_state_abbreviation", "location_state") \
...     .withColumnRenamed("Iso_3166-3_Area_Code", "iso_area_code")
>>> df_georef2 = df_georef2.drop("Geo_Shape")
>>> df_georef2.show(5, truncate=False)

```

Geo_Point	Year	code_state	name_state	iso_area_code	Type	location_state	State_FIPS_Code	State_GNIS_Code
31.447200101453458, -99.31711604283118	2022	48	Texas	USA	State	TX	null	1779881
38.64257169984573, -88.61369740655968	2022	54	West Virginia	USA	State	WV	null	1779885
18.215706855012684, -66.41465042883969	2022	72	Puerto Rico	PRI	outlying area	PR	null	1779888
40.10998794109383, -74.65593977351195	2022	34	New Jersey	USA	State	NJ	null	1779795
20.995094555897666, -158.10992727137122	2022	15	Hawaii	USA	State	HI	null	1779782

only showing top 5 rows

Modificaiion de rating

2 Redondear la columna 'rating' y castear a int

```
df_rentacar = df_rentacar.withColumn("rating", round(col("rating")).cast("int"))
```

```

>>> df_rentacar = df_rentacar.withColumn("rating", round(col("rating")).cast("int"))
>>> df_rentacar.show(5)

```

fueltype	rating	rentertripstaken	reviewcount	location_city	location_country	location_latitude	location_longitude	location_state	owner_id	rate_daily	vehicle_make	vehicle_model	vehicle_type	vehicle_year
ELECTRIC	5	13	12	Seattle	US	47.449107	-122.308841	WA	12847615	135	Tesla	Model X	suv	2019
ELECTRIC	5	2	1	Tijeras	US	35.11106	-106.276551	NM	15621242	190	Tesla	Model X	suv	2018
HYBRID	5	28	24	Albuquerque	US	35.127163	-106.566681	NM	10199256	35	Toyota	Prius	car	2012
GASOLINE	5	21	20	Albuquerque	US	35.149726	-106.711425	NM	9365496	75	Ford	Mustang	car	2018
GASOLINE	5	3	1	Albuquerque	US	35.208659	-106.601008	NM	3553565	47	Chrysler	Sebring	car	2010

only showing top 5 rows

En el join elijo un "inner join" para tener los datos coincidentes de ambos DF y no generar nulos con otras uniones, solo nos enfocamos en los resultados donde ambos DF tiene coincidencia

Realizar un inner join por la columna 'location_state'

renta_join = df_rentacar.join(df_georef2, on="location_state", how="inner")

Mostrar las primeras filas del resultado

renta_join.show(10, truncate=False)

Verificar el esquema del DataFrame combinado

renta_join.printSchema()

```
>>> renta_join = df_rentacar.join(df_georef2, on="location_state", how="inner")
>>> renta_join.show(10, truncate=False)
```

location_state	fueltype	rating	reentertripstaken	reviewcount	location_city	location_country	location_latitude	location_longitude	owner_id	rate_daily	vehicle_make	vehicle_model	vehicle_type	vehicle_year
TX	NULL	10	0	10	San Antonio	USA	29.444692	-98.478055	2737121	25	Mazda	MAZDA2	car	2012
TX	GASOLINE	5	1	1	San Antonio	USA	29.563421	-98.483081	812251	271	Land Rover	Range Rover Sport	suv	2016
TX	GASOLINE	5	1	1	San Antonio	USA	29.365085	-98.736017	1285519	42	Jeep	Patriot	suv	2015
TX	GASOLINE	5	10	5	San Antonio	USA	29.412377	-98.724665	12125275	47	Mercedes-Benz	GL-Class	suv	2010
TX	GASOLINE	5	11	10	San Antonio	USA	29.652499	-98.477879	812251	195	Cadillac	Escalade	suv	2015
TX	GASOLINE	5	11	10	San Antonio	USA	29.44302	-98.692128	6107266	69	Mitsubishi	Lancer	car	2010
TX	GASOLINE	5	14	11	San Antonio	USA	29.425435	-98.689523	4115779	28	Toyota	Yaris	car	2007
TX	GASOLINE	5	10	10	San Antonio	USA	29.466763	-100.985711	439131	368	BMW	M4	car	2018
TX	GASOLINE	3	12	2	San Antonio	USA	29.486385	-98.715862	8510171	65	Chevrolet	Impala	car	2017
TX	NULL	10	10	10	San Antonio	USA	29.405642	-98.711994	7892292	75	Ford	Transit-350 Wagon	van	2019

only showing top 10 rows

```
>>> renta_join.printSchema()
root
 |-- location_state: string (nullable = true)
 |-- fueltype: string (nullable = true)
 |-- rating: integer (nullable = true)
 |-- reentertripstaken: string (nullable = true)
 |-- reviewcount: string (nullable = true)
 |-- location_city: string (nullable = true)
 |-- location_country: string (nullable = true)
 |-- location_latitude: string (nullable = true)
 |-- location_longitude: string (nullable = true)
 |-- owner_id: string (nullable = true)
 |-- rate_daily: string (nullable = true)
 |-- vehicle_make: string (nullable = true)
 |-- vehicle_model: string (nullable = true)
 |-- vehicle_type: string (nullable = true)
 |-- vehicle_year: string (nullable = true)
 |-- Geo_Point: string (nullable = true)
 |-- Year: integer (nullable = true)
 |-- code_state: integer (nullable = true)
 |-- name_state: string (nullable = true)
 |-- iso_area_code: string (nullable = true)
 |-- Type: string (nullable = true)
 |-- State_FIPS_Code: string (nullable = true)
 |-- State_GNIS_Code: integer (nullable = true)
```

sobre este nuevo DF hacer las siguientes operaciones

Eliminar los registros con rating nulo

Cambiar mayúsculas por minúsculas en 'fuelType'

Excluir el estado Texas

```
# Eliminar los registros con rating nulo
```

```
renta_join_cleaned = renta_join.filter(col("rating").isNotNull())
```

```
# Cambiar mayúsculas por minúsculas en la columna 'fuelType'
```

```
renta_join_cleaned = renta_join_cleaned.withColumn('fuelType',  
col('fuelType').lower())
```

```
# Excluir el estado Texas (TX)
```

```
renta_join_cleaned = renta_join_cleaned.filter(col('location_state') != 'TX')
```

```
# Mostrar el resultado después de las operaciones
```

```
renta_join_cleaned.show(100, truncate=False)
```

```
# primero sacamos las columnas que no vamos a utilizar en HIVE
```

```
df_rental_hive = renta_join_cleaned.drop('Geo_Point', 'vehicle_year', 'Code_State',  
'Name_State', 'iso_area_code', 'Type', 'US_Postal_state', 'State_FIPS_Code',  
'State_GNIS_Code', 'state_code')
```

```
#renombramos y casteamos las columnas y datos
```

```
df_rental_hive = df_rental_hive.selectExpr(  
    "fuelType as fueltype",  
    "CAST(rating AS INT) as rating",  
    "CAST(rentertripstaken AS INT) as rentertripstaken",  
    "CAST(reviewcount AS INT) as reviewcount",  
    "location_city as city",  
    "location_state as state_name",  
    "CAST(rate_daily AS INT) as rate_daily",  
    "vehicle_make as make",  
    "vehicle_model as model",  
    "CAST(Year AS INT) as year"
```

)

```
>>> df_rental_hive = df_rental_hive.selectExpr(
...     "fuelType as fueltype",
...     "CAST(rating AS INT) as rating",
...     "CAST(rentertripstaken AS INT) as rentertripstaken",
...     "CAST(reviewcount AS INT) as reviewcount",
...     "location_city as city",
...     "location_state as state_name",
...     "CAST(rate_daily AS INT) as rate_daily", # Usar el nombre correcto
...     "vehicle_make as make",
...     "vehicle_model as model",
...     "CAST(Year AS INT) as year"
... )
>>> df_rental_hive.show(5, truncate=False)
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|fueltype|rating|rentertripstaken|reviewcount|city      |state_name|rate_daily|make      |model      |year|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|gasoline|5     |34              |30         |Weirton   |WV        |50        |Audi      |A4         |2022|
|gasoline|5     |36              |26         |Weirton   |WV        |34        |Toyota    |Camry      |2022|
|gasoline|5     |6               |4          |Weirton   |WV        |94        |Audi      |A6         |2022|
|gasoline|null    |0               |0          |Weirton   |WV        |98        |Mercedes-Benz|GLE-Class |2022|
|gasoline|5     |84              |71         |Jersey City|NJ        |37        |smart     |fortwo     |2022|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
only showing top 5 rows
```

```
>>> df_rental_hive.printSchema()
root
 |-- fueltype: string (nullable = true)
 |-- rating: integer (nullable = true)
 |-- rentertripstaken: integer (nullable = true)
 |-- reviewcount: integer (nullable = true)
 |-- city: string (nullable = true)
 |-- state_name: string (nullable = true)
 |-- rate_daily: integer (nullable = true)
 |-- make: string (nullable = true)
 |-- model: string (nullable = true)
 |-- year: integer (nullable = true)
```

Ahora ya tenemos la info lista para insertar en Hive

```
hive> DESCRIBE car_rental_analytics;
OK
fueltype          string
tipo              string
rating            int
rentertripstaken  int
reviewcount       int
city              string
state_name        string
rate_daily        int
make              string
model             string
year              int
Time taken: 0.056 seconds, Fetched: 11 row(s)
hive>
```

#INSERTAMOS

```
df_rental_hive.write.saveAsTable('car_rental_analytics', mode='overwrite')
```

```
>>> df_rental_hive.write.saveAsTable('car_rental_analytics', mode='overwrite')
>>>
```

```
>>> df_rental_hive.write.saveAsTable('car_rental_analytics', mode='overwrite')
>>> df_rental_hive.show(5, truncate=False)
```

```
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|fueltype|rating|rentertripstaken|reviewcount|city
|state_name|rate_daily|make |model |year|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|ELECTRIC|5 |13 |12 |Seattle |WA |135 |Tesla |Model
X|2019|
|ELECTRIC|5 |2 |1 |Tijeras |NM |190 |Tesla |Model
X|2018|
|HYBRID |5 |28 |24 |Albuquerque|NM |35 |Toyota |Prius
|2012|
|GASOLINE|5 |21 |20 |Albuquerque|NM |75 |Ford
|Mustang|2018|
|GASOLINE|5 |3 |1 |Albuquerque|NM |47
|Chrysler|Sebring|2010|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
```

only showing top 5 rows

```

>>> df_renta_hive.printSchema()
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'df_renta_hive' is not defined
>>> df_renta_hive.printSchema
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'df_renta_hive' is not defined
>>> df_rental_hive.printSchema()
root
 |-- fueltype: string (nullable = true)
 |-- rating: integer (nullable = true)
 |-- rentertripstaken: integer (nullable = true)
 |-- reviewcount: integer (nullable = true)
 |-- city: string (nullable = true)
 |-- state_name: string (nullable = true)
 |-- rate_daily: integer (nullable = true)
 |-- make: string (nullable = true)
 |-- model: string (nullable = true)
 |-- year: integer (nullable = true)

>>> df_rental_hive.write.saveAsTable('car_rental_analytics', mode='overwrite')
>>>

```

- 4.- Realizar un proceso automático en Airflow que orqueste los pipelines creados en los puntos anteriores. Crear dos tareas:
- Un DAG padre que ingente los archivos y luego llame al DAG hijo
 - Un DAG hijo que procese la información y la cargue en Hive

Se arman dos DAG el padre llama al dag hijo cuando termina la ingesta

parent_dag.py se genera en el directorio /home/hadoop/airflow/dags y ya tenemos los archivos

ingest_car.sh

y

car_transform.py

en el directorio

```

adoop@d5e109c82f52:~/scripts$ ls
0                                car_transform.py  derby.log  ingest_car.sh
eroport_transform2.py  data-aviacion.sh  ingest.sh  ingest_ema.sh
adoop@d5e109c82f52:~/scripts$

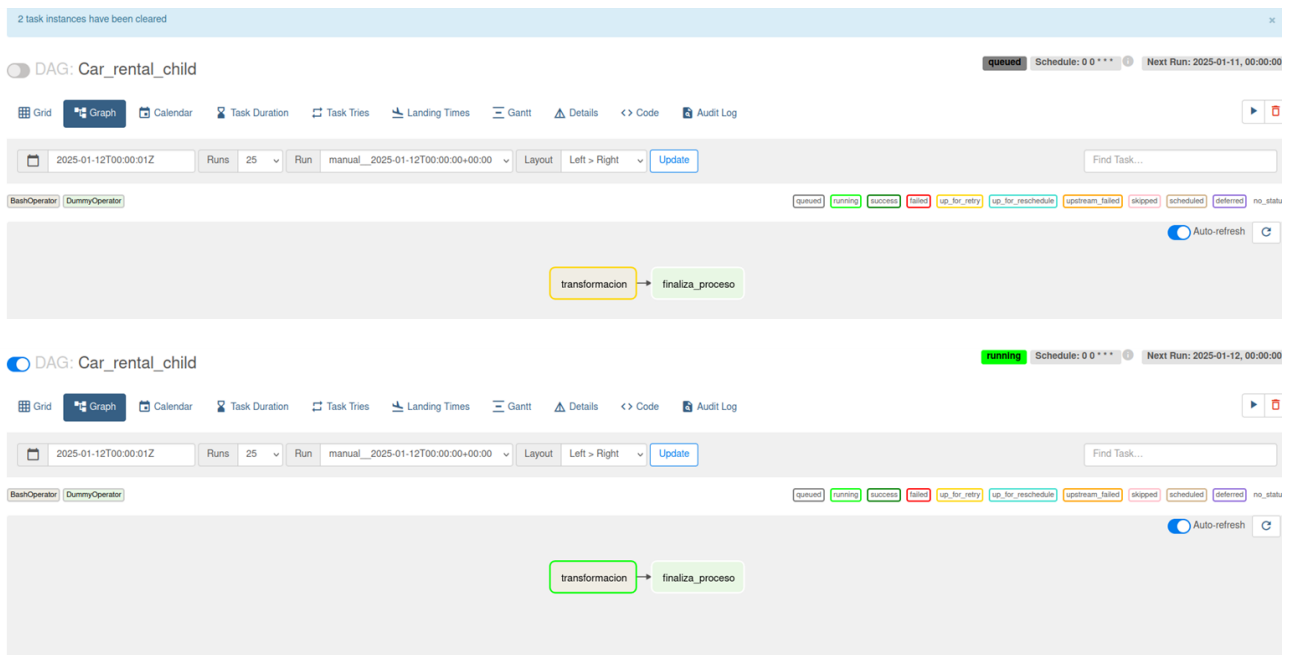
```

damos los permisos

chmod 555 rev_car_transform.py

Código de los dags

DAG	Owner	Runs	Schedule	Last Run	Next Run	Recent Tasks	Actions	Links
Aviacion	airflow	2	0 0 * * *	2025-01-01, 22:18:39	2025-01-11, 00:00:00	1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80 81 82 83 84 85 86 87 88 89 90 91 92 93 94 95 96 97 98 99 100 101 102 103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119 120 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136 137 138 139 140 141 142 143 144 145 146 147 148 149 150 151 152 153 154 155 156 157 158 159 160 161 162 163 164 165 166 167 168 169 170 171 172 173 174 175 176 177 178 179 180 181 182 183 184 185 186 187 188 189 190 191 192 193 194 195 196 197 198 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213 214 215 216 217 218 219 220 221 222 223 224 225 226 227 228 229 230 231 232 233 234 235 236 237 238 239 240 241 242 243 244 245 246 247 248 249 250 251 252 253 254 255 256 257 258 259 260 261 262 263 264 265 266 267 268 269 270 271 272 273 274 275 276 277 278 279 280 281 282 283 284 285 286 287 288 289 290 291 292 293 294 295 296 297 298 299 300 301 302 303 304 305 306 307 308 309 310 311 312 313 314 315 316 317 318 319 320 321 322 323 324 325 326 327 328 329 330 331 332 333 334 335 336 337 338 339 340 341 342 343 344 345 346 347 348 349 350 351 352 353 354 355 356 357 358 359 360 361 362 363 364 365 366 367 368 369 370 371 372 373 374 375 376 377 378 379 380 381 382 383 384 385 386 387 388 389 390 391 392 393 394 395 396 397 398 399 400 401 402 403 404 405 406 407 408 409 410 411 412 413 414 415 416 417 418 419 420 421 422 423 424 425 426 427 428 429 430 431 432 433 434 435 436 437 438 439 440 441 442 443 444 445 446 447 448 449 450 451 452 453 454 455 456 457 458 459 460 461 462 463 464 465 466 467 468 469 470 471 472 473 474 475 476 477 478 479 480 481 482 483 484 485 486 487 488 489 490 491 492 493 494 495 496 497 498 499 500 501 502 503 504 505 506 507 508 509 510 511 512 513 514 515 516 517 518 519 520 521 522 523 524 525 526 527 528 529 530 531 532 533 534 535 536 537 538 539 540 541 542 543 544 545 546 547 548 549 550 551 552 553 554 555 556 557 558 559 560 561 562 563 564 565 566 567 568 569 570 571 572 573 574 575 576 577 578 579 580 581 582 583 584 585 586 587 588 589 590 591 592 593 594 595 596 597 598 599 600 601 602 603 604 605 606 607 608 609 610 611 612 613 614 615 616 617 618 619 620 621 622 623 624 625 626 627 628 629 630 631 632 633 634 635 636 637 638 639 640 641 642 643 644 645 646 647 648 649 650 651 652 653 654 655 656 657 658 659 660 661 662 663 664 665 666 667 668 669 670 671 672 673 674 675 676 677 678 679 680 681 682 683 684 685 686 687 688 689 690 691 692 693 694 695 696 697 698 699 700 701 702 703 704 705 706 707 708 709 710 711 712 713 714 715 716 717 718 719 720 721 722 723 724 725 726 727 728 729 730 731 732 733 734 735 736 737 738 739 740 741 742 743 744 745 746 747 748 749 750 751 752 753 754 755 756 757 758 759 760 761 762 763 764 765 766 767 768 769 770 771 772 773 774 775 776 777 778 779 780 781 782 783 784 785 786 787 788 789 790 791 792 793 794 795 796 797 798 799 800 801 802 803 804 805 806 807 808 809 810 811 812 813 814 815 816 817 818 819 820 821 822 823 824 825 826 827 828 829 830 831 832 833 834 835 836 837 838 839 840 841 842 843 844 845 846 847 848 849 850 851 852 853 854 855 856 857 858 859 860 861 862 863 864 865 866 867 868 869 870 871 872 873 874 875 876 877 878 879 880 881 882 883 884 885 886 887 888 889 890 891 892 893 894 895 896 897 898 899 900 901 902 903 904 905 906 907 908 909 910 911 912 913 914 915 916 917 918 919 920 921 922 923 924 925 926 927 928 929 930 931 932 933 934 935 936 937 938 939 940 941 942 943 944 945 946 947 948 949 950 951 952 953 954 955 956 957 958 959 960 961 962 963 964 965 966 967 968 969 970 971 972 973 974 975 976 977 978 979 980 981 982 983 984 985 986 987 988 989 990 991 992 993 994 995 996 997 998 999 1000 1001 1002 1003 1004 1005 1006 1007 1008 1009 1010 1011 1012 1013 1014 1015 1016 1017 1018 1019 1020 1021 1022 1023 1024 1025 1026 1027 1028 1029 1030 1031 1032 1033 1034 1035 1036 1037 1038 1039 1040 1041 1042 1043 1044 1045 1046 1047 1048 1049 1050 1051 1052 1053 1054 1055 1056 1057 1058 1059 1060 1061 1062 1063 1064 1065 1066 1067 1068 1069 1070 1071 1072 1073 1074 1075 1076 1077 1078 1079 1080 1081 1082 1083 1084 1085 1086 1087 1088 1089 1090 1091 1092 1093 1094 1095 1096 1097 1098 1099 1100 1101 1102 1103 1104 1105 1106 1107 1108 1109 1110 1111 1112 1113 1114 1115 1116 1117 1118 1119 1120 1121 1122 1123 1124 1125 1126 1127 1128 1129 1130 1131 1132 1133 1134 1135 1136 1137 1138 1139 1140 1141 1142 1143 1144 1145 1146 1147 1148 1149 1150 1151 1152 1153 1154 1155 1156 1157 1158 1159 1160 1161 1162 1163 1164 1165 1166 1167 1168 1169 1170 1171 1172 1173 1174 1175 1176 1177 1178 1179 1180 1181 1182 1183 1184 1185 1186 1187 1188 1189 1190 1191 1192 1193 1194 1195 1196 1197 1198 1199 1200 1201 1202 1203 1204 1205 1206 1207 1208 1209 1210 1211 1212 1213 1214 1215 1216 1217 1218 1219 1220 1221 1222 1223 1224 1225 1226 1227 1228 1229 1230 1231 1232 1233 1234 1235 1236 1237 1238 1239 1240 1241 1242 1243 1244 1245 1246 1247 1248 1249 1250 1251 1252 1253 1254 1255 1256 1257 1258 1259 1260 1261 1262 1263 1264 1265 1266 1267 1268 1269 1270 1271 1272 1273 1274 1275 1276 1277 1278 1279 1280 1281 1282 1283 1284 1285 1286 1287 1288 1289 1290 1291 1292 1293 1294 1295 1296 1297 1298 1299 1300 1301 1302 1303 1304 1305 1306 1307 1308 1309 1310 1311 1312 1313 1314 1315 1316 1317 1318 1319 1320 1321 1322 1323 1324 1325 1326 1327 1328 1329 1330 1331 1332 1333 1334 1335 1336 1337 1338 1339 1340 1341 1342 1343 1344 1345 1346 1347 1348 1349 1350 1351 1352 1353 1354 1355 1356 1357 1358 1359 1360 1361 1362 1363 1364 1365 1366 1367 1368 1369 1370 1371 1372 1373 1374 1375 1376 1377 1378 1379 1380 1381 1382 1383 1384 1385 1386 1387 1388 1389 1390 1391 1392 1393 1394 1395 1396 1397 1398 1399 1400 1401 1402 1403 1404 1405 1406 1407 1408 1409 1410 1411 1412 1413 1414 1415 1416 1417 1418 1419 1420 1421 1422 1423 1424 1425 1426 1427 1428 1429 1430 1431 1432 1433 1434 1435 1436 1437 1438 1439 1440 1441 1442 1443 1444 1445 1446 1447 1448 1449 1450 1451 1452 1453 1454 1455 1456 1457 1458 1459 1460 1461 1462 1463 1464 1465 1466 1467 1468 1469 1470 1471 1472 1473 1474 1475 1476 1477 1478 1479 1480 1481 1482 1483 1484 1485 1486 1487 1488 1489 1490 1491 1492 1493 1494 1495 1496 1497 1498 1499 1500 1501 1502 1503 1504 1505 1506 1507 1508 1509 1510 1511 1512 1513 1514 1515 1516 1517 1518 1519 1520 1521 1522 1523 1524 1525 1526 1527 1528 1529 1530 1531 1532 1533 1534 1535 1536 1537 1538 1539 1540 1541 1542 1543 1544 1545 1546 1547 1548 1549 1550 1551 1552 1553 1554 1555 1556 1557 1558 1559 1560 1561 1562 1563 1564 1565 1566 1567 1568 1569 1570 1571 1572 1573 1574 1575 1576 1577 1578 1579 1580 1581 1582 1583 1584 1585 1586 1587 1588 1589 1590 1591 1592 1593 1594 1595 1596 1597 1598 1599 1600 1601 1602 1603 1604 1605 1606 1607 1608 1609 1610 1611 1612 1613 1614 1615 1616 1617 1618 1619 1620 1621 1622 1623 1624 1625 1626 1627 1628 1629 1630 1631 1632 1633 1634 1635 1636 1637 1638 1639 1640 1641 1642 1643 1644 1645 1646 1647 1648 1649 1650 1651 1652 1653 1654 1655 1656 1657 1658 1659 1660 1661 1662 1663 1664 1665 1666 1667 1668 1669 1670 1671 1672 1673 1674 1675 1676 1677 1678 1679 1680 1681 1682 1683 1684 1685 1686 1687 1688 1689 1690 1691 1692 1693 1694 1695 1696 1697 1698 1699 1700 1701 1702 1703 1704 1705 1706 1707 1708 1709 1710 1711 1712 1713 1714 1715 1716 1717 1718 1719 1720 1721 1722 1723 1724 1725 1726 1727 1728 1729 1730 1731 1732 1733 1734 1735 1736 1737 1738 1739 1740 1741 1742 1743 1744 1745 1746 1747 1748 1749 1750 1751 1752 1753 1754 1755 1756 1757 1758 1759 1760 1761 1762 1763 1764 1765 1766 1767 1768 1769 1770 1771 1772 1773 1774 1775 1776 1777 1778 1779 1780 1781 1782 1783 1784 1785 1786 1787 1788 1789 1790 1791 1792 1793 1794 1795 1796 1797 1798 1799 1800 1801 1802 1803 1804 1805 1806 1807 1808 1809 1810 1811 1812 1813 1814 1815 1816 1817 1818 1819 1820 1821 1822 1823 1824 1825 1826 1827 1828 1829 1830 1831 1832 1833 1834 1835 1836 1837 1838 1839 1840 1841 1842 1843 1844 1845 1846 1847 1848 1849 1850 1851 1852 1853 1854 1855 1856 1857 1858 1859 1860 1861 1862 1863 1864 1865 1866 1867 1868 1869 1870 1871 1872 1873 1874 1875 1876 1877 1878 1879 1880 1881 1882 1883 1884 1885 1886 1887 1888 1889 1890 1891 1892 1893 1894 1895 1896 1897 1898 1899 1900 1901 1902 1903 1904 1905 1906 1907 1908 1909 1910 1911 1912 1913 1914 1915 1916 1917 1918 1919 1920 1921 1922 1923 1924 1925 1926 1927 1928 1929 1930 1931 1932 1933 1934 1935 1936 1937 1938 1939 1940 1941 1942 1943 1944 1945 1946 1947 1948 1949 1950 1951 1952 1953 1954 1955 1956 1957 1958 1959 1960 1961 1962 1963 1964 1965 1966 1967 1968 1969 1970 1971 1972 1973 1974 1975 1976 1977 1978 1979 1980 1981 1982 1983 1984 1985 1986 1987 1988 1989 1990 1991 1992 1993 1994 1995 1996 1997 1998 1999 2000 2001 2002 2003 2004 2005 2006 2007 2008 2009 2010 2011 2012 2013 2014 2015 2016 2017 2018 2019 2020 2021 2022 2023 2024 2025 2026 2027 2028 2029 2030 2031 2032 2033 2034 2035 2036 2037 2038 2039 2040 2041 2042 2043 2044 2045 2046 2047 2048 2049 2050 2051 2052 2053 2054 2055 2056 2057 2058 2059 2060 2061 2062 2063 2064 2065 2066 2067 2068 2069 2070 2071 2072 2073 2074 2075 2076 2077 2078 2079 2080 2081 2082 2083 2084 2085 2086 2087 2088 2089 2090 2091 2092 2093 2094 2095 2096 2097 2098 2099 2100 2101 2102 2103 2104 2105 2106 2107 2108 2109 2110 2111 2112 2113 2114 2115 2116 2117 2118 2119 2120 2121 2122 2123 2124 2125 2126 2127 2128 2129 2130 2131 2132 2133 2134 2135 2136 2137 2138 2139 2140 2141 2142 2143 2144 2145 2146 2147 2148 2149 2150 2151 2152 2153 2154 2155 2156 2157 2158 2159 2160 2161 2162 2163 2164 2165 2166 2167 2168 2169 2170 2171 2172 2173 2174 2175 2176 2177 2178 2179 2180 2181 2182 2183 2184 2185 2186 2187 2188 2189 2190 2191 2192 2193 2194 2195 2196 2197 2198 2199 2200 2201 2202 2203 2204 2205 2206 2207 2208 2209 2210 2211 2212 2213 2214 2215 2216 2217 2218 2219 2220 2221 2222 2223 2224 2225 2226 2227 2228 2229 2230 2231 2232 2233 2234 2235 2236 2237 2238 2239 2240 2241 2242 2243 2244 2245 2246 2247 2248 2249 2250 2251 2252 2253 2254 2255 2256 2257 2258 2259 2260 2261 2262 2263 2264 2265 2266 2267 2268 2269 2270 2271 2272 2273 2274 2275 2276 2277 2278 2279 2280 2281 2282 2283 2284 2285 2286 2287 2288 2289 2290 2291 2292 2293 2294 2295 2296 2297 2298 2299 2300 2301 2302 2303 2304 2305 2306 2307 2308 2309 2310 2311 2312 2313 2314 2315 2316 2317 2318 2319 2320 2321 2322 2323 2324 2325 2326 2327 2328 2329 2330 2331 2332 2333 2334 2335 2336 2337 2338 2339 2340 2341 2342 2343 2344 2345 2346 2347 2348 2349 2350 2351 2352 2353 2354 2355 2356 2357 2358 2359 2360 2361 2362 2363 2364 2365 2366 2367 2368 2369 2370 2371 2372 2373 2374 2375 2376 2377 2378 2379 2380 2381 2382 2383 2384 2385 2386 2387 2388 2389 2390 2391 2392 2393 2394 2395 2396 2397 2398 2399 2400 2401 2402 2403 2404 2405 2406 2407 2408 2409 2410 2411 2412 2413 2414 2415 2416 2417 2418 2419 2420 2421 2422 2423 2424 2425 2426 2427 2428 2429 2430 2431 2432 2433 2434 2435 2436 2437 2438 2439 2440 2441 2442 2443 2444 2445 2446 2447 2448 2449 2450 2451 2452 2453 2454 2455 2456 2457 2458 2459 2460 2461 2462 2463 2464 2465 2466 2467 2468 2469 2470 2471 2472 2473 2474 2475 2476 2477 2478 2479 2480 2481 2482 2483 2484 2485 2486 2487 2488 2489 2490 2491 2492 2493 2494 2495 2496 2497 2498 2499 2500 2501 2502 2503 2504 2505 2506 2507 2508 2509 2510 2511 2512 2513 2514 2515 2516 2517 2518 2519 2520 2521 2522 2523 2524 2525 2526 2527 2528 2529 2530 2531 2532 2533 2534 2535 2536 2537 2538 2539 2540 2541 2542 2543 2544 2545 2546 2547 2548 2549 2550 2551 2552 2553 2554 2555 2556 2557 2558 2559 2560 2561 2562 2563 2564 2565 2566 2567 2568 2569 2570 2571 2572 2573 2574 2575 2576 2577 2578 2579 2580 2581 2582 2583 2584 2585 2586 2587 2588 2589 2590 2591 2592 2593 2594 2595 2596 2597 2598 2599 2600 2601 2602 2603 2604 2605 2606 2607 2608 2609 2610 2611 2612 2613 2614 2615 26		



parent_dag.py responsable de la ingesta

```
from datetime import timedelta
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.operators.trigger_dagrun import TriggerDagRunOperator
from airflow.utils.dates import days_ago
```

```
args = {
    'owner': 'airflow',
}
```

```
with DAG(
    dag_id='Car_rental_parent',
    default_args=args,
    schedule_interval='0 0 * * *',
    start_date=days_ago(1),
    catchup=False,
    dagrun_timeout=timedelta(minutes=60),
    tags=['ingest', 'trigger_target'],
    params={"example_key": "example_value"},
) as dag:
```



```

ingest = BashOperator(
    task_id='ingesta',
    bash_command='/usr/bin/sh /home/hadoop/scripts/rev_ingest_car.sh ',
)

```

```

trigger_target = TriggerDagRunOperator(
    task_id = 'trigger_target',
    trigger_dag_id = 'Car_rental_child',
    execution_date = '{{ ds }}',
    reset_dag_run = True,
    wait_for_completion = True,
    poke_interval = 30
)

```

```

ingest >> trigger_target

```

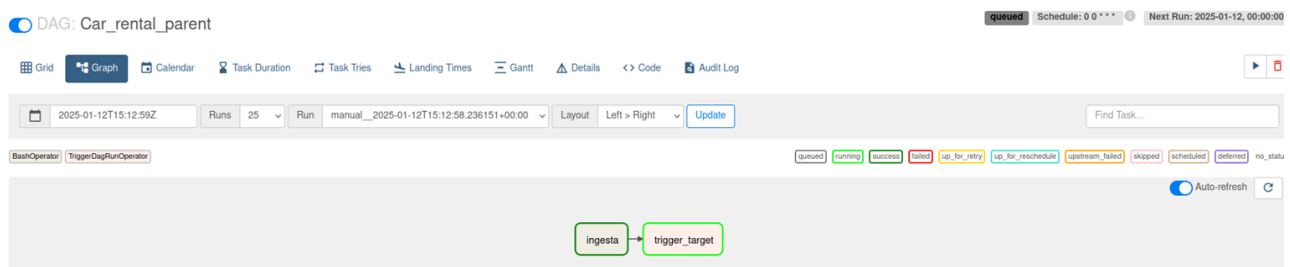
```

if __name__ == "__main__":
    dag.cli()

```

ejecutamos el dag

airflow dags trigger car_parent_dag



y el del child_dag

```

from datetime import timedelta
from airflow import DAG
from airflow.operators.bash import BashOperator

```

```
from airflow.operators.dummy import DummyOperator
from airflow.utils.dates import days_ago
```

```
args = {
    'owner': 'airflow',
}
```

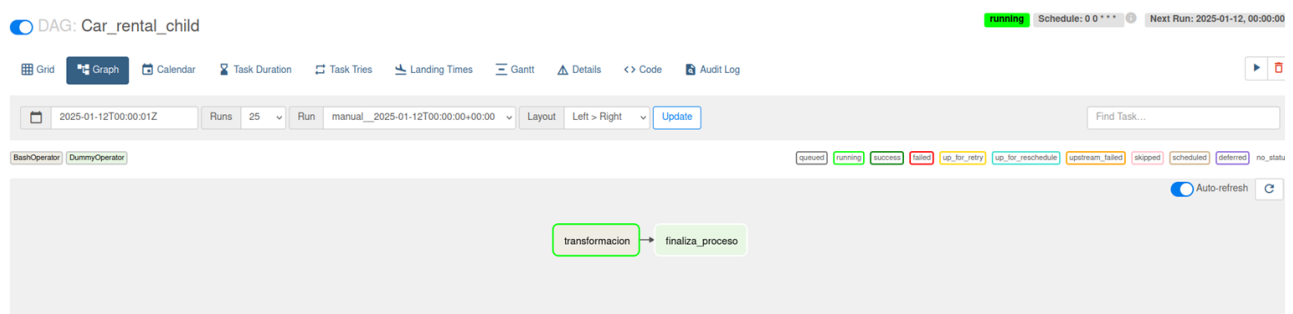
```
with DAG(
    dag_id='Car_rental_child',
    default_args=args,
    schedule_interval='0 0 * * *',
    start_date=days_ago(1),
    catchup=False,
    dagrun_timeout=timedelta(minutes=60),
    tags=['ingest', 'transform'],
    params={"example_key": "example_value"},
) as dag:
```

```
    finaliza_proceso = DummyOperator(
        task_id='finaliza_proceso',
    )
```

```
    transform = BashOperator(
        task_id='transformacion',
        bash_command='ssh hadoop@172.17.0.2 /home/hadoop/spark/bin/spark-submit --files /home/hadoop/hive/conf/hive-site.xml /home/hadoop/scripts/rev_car__transform.py ',
    )
```

```
    transform >> finaliza_proceso
```

```
if __name__ == "__main__":
    dag.cli()
```



y damos permiso de ejecución

```
chmod +x rev_parent_dag.py
```

```
chmod +x rev_child_dag.py
```

tengo cargados los files de los dags en

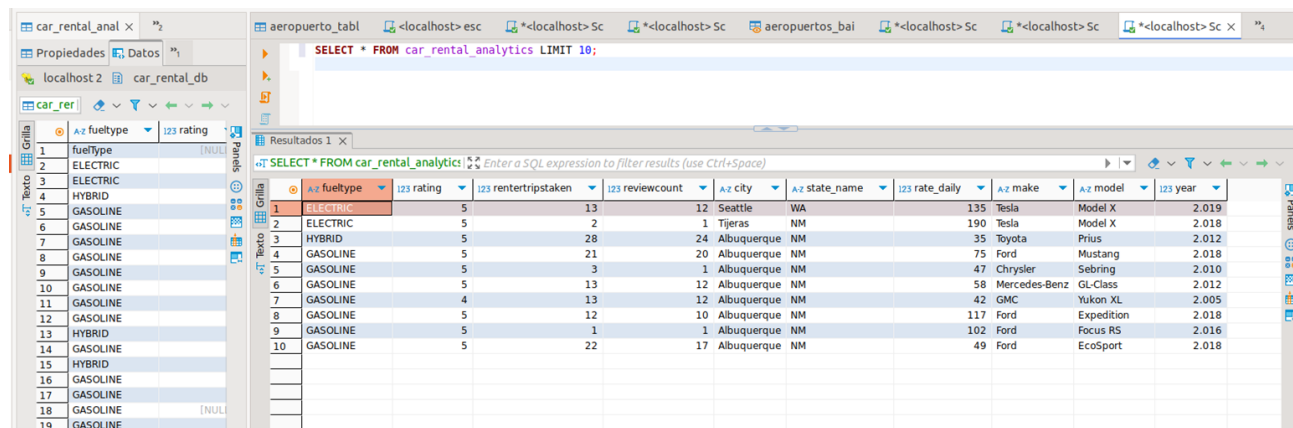
/home/hadoop/airflow/dags

```
hadoop@hadoop5e109c82f52:~/airflow/dags$ ls
2dag_vuelos.py  dag_ema.py  dag_vuelos.py  example-DAG.py  ingest-transform.py  rev_child_dag.py  rev_parent_dag.py
hadoop@hadoop5e109c82f52:~/airflow/dags$
```

Tanto el “airflow webserver” y el “schedule” están corriendo

```
hadoop@hadoop5e109c82f52:~/airflow/dags$ ps aux | grep "airflow webserver"
hadoop 33918 0.0 0.0 3312 1664 pts/2 S+ 12:40 0:00 grep --color=auto airflow webserver
hadoop@hadoop5e109c82f52:~/airflow/dags$ ps aux | grep "airflow scheduler"
hadoop 5745 3.9 0.6 131652 104344 ? S 05:22 17:11 /usr/bin/python3 /home/hadoop/.local/bin/airflow scheduler
hadoop 5749 0.9 0.6 130188 101844 ? S 05:22 4:11 airflow scheduler -- DagFileProcessorManager
hadoop 33940 0.0 0.0 3444 1792 pts/2 S+ 12:40 0:00 grep --color=auto airflow scheduler
```

5.- Datos insertado en Hive y vistos desde Dbeaver



	fueltype	rating	rentertripstaken	reviewcount	city	state_name	rate_daily	make	model	year
1	ELECTRIC	5	13	12	Seattle	WA	135	Tesla	Model X	2.019
2	ELECTRIC	5	2	1	Tjeras	NM	190	Tesla	Model X	2.018
3	HYBRID	5	28	24	Albuquerque	NM	35	Toyota	Prius	2.012
4	GASOLINE	5	21	20	Albuquerque	NM	75	Ford	Mustang	2.018
5	GASOLINE	5	3	1	Albuquerque	NM	47	Chrysler	Sebring	2.010
6	GASOLINE	5	13	12	Albuquerque	NM	58	Mercedes-Benz	GL-Class	2.012
7	GASOLINE	4	13	12	Albuquerque	NM	42	GMC	Yukon XL	2.005
8	GASOLINE	5	12	10	Albuquerque	NM	117	Ford	Expedition	2.018
9	GASOLINE	5	1	1	Albuquerque	NM	102	Ford	Focus RS	2.016
10	GASOLINE	5	22	17	Albuquerque	NM	49	Ford	EcoSport	2.018

a.- Cantidad de alquileres de autos, teniendo en cuenta sólo los vehículos ecológicos (fuelType hibrido o eléctrico) y con un rating de al menos 4.

```
SELECT COUNT(*) AS total rentals  
FROM car_rental_analytics  
WHERE fueltype IN ('HYBRID', 'ELECTRIC')  
AND rating >= 4  
AND fueltype IS NOT NULL  
AND rating IS NOT NULL;
```

```

SELECT COUNT(*) AS total_rentals
FROM car_rental_analytics
WHERE fueltype IN ('HYBRID', 'ELECTRIC')
AND rating >= 4
LIMIT 10;

```

Resultados 1 x

SELECT COUNT(*) AS total_rentals FR | Enter a SQL expression to filter results (use Ctrl+Space)

Grilla	total_rentals
1	771

12-01

```

--5.a rev1201 Cantidad de alquileres de autos, teniendo en cuenta sólo los vehículos ecológicos (fuelType híbrido
-- y con un rating de al menos 4.
SELECT
SUM(rentertripstaken) AS total_rentals
FROM
car_rental_analytics
WHERE
LOWER(fueltype) IN ('hybrid', 'electric') -- Verificar vehículos ecológicos
AND rating >= 4; -- Rating de al menos 4

```

Resultados 1 x

SELECT SUM(rentertripstaken) AS total_rei | Enter a SQL expression to filter results (use Ctrl+Space)

Grilla	total_rentals
1	26.949

b.-los 5 estados con menor cantidad de alquileres (mostrar query y visualización)

```

SELECT
state_name,
SUM(rentertripstaken) AS total_rentals
FROM
car_rental_analytics
WHERE state_name IS NOT NULL AND state_name != ''
GROUP BY
state_name
ORDER BY
total_rentals ASC
LIMIT 5;

```

--


```
--5 b. los 5 estados con menor cantidad de alquileres

SELECT
    state_name,
    SUM(rentertripstaken) AS total_rentals
FROM
    car_rental_analytics
WHERE state_name IS NOT NULL AND state_name != ''
GROUP BY
    state_name
ORDER BY
    total_rentals ASC
LIMIT 5;
```

Resultados 1 X

SELECT state_name, SUM(rentertripstaken) Enter a SQL expression to filter

Grilla	A-Z state_name		123 total_rentals	
1	MT		7	
2	AR		43	
3	NH		51	
4	WV		76	
5	MS		107	



Este gráfico lo realicé en PowerBI y muestra la gráfica de la consulta realizada donde se puede ver que los estados de:

- 1.- Montana (MT) con 7 alquileres
- 2.- Arkansas(AR) con 43,
- 3.- New Hampshire con 51 y
- 4.- West Virginia(WV) con 76 tiene menos de 100 alquileres.

Si la estrategia del negocio necesita saber cuales son este tipo de estada para tomar acciones de promoción o reducción de servicios, este gráfico da una imagen clara de la cantidad de de cada estado.

c.- los 10 modelos (junto con su marca) de autos más rentados (mostrar query y visualización)

```
SELECT
  make AS brand,
  model,
  SUM(rentertripstaken) AS total_rentals
FROM
  car_rental_analytics
GROUP BY
  make, model
ORDER BY
```

total_rentals **DESC**
LIMIT 10;

--5.c los 10 modelos (junto con su marca) de autos más rent

```


SELECT
    make AS brand,
    model,
    SUM(rentertripstaken) AS total_rentals
FROM
    car_rental_analytics
GROUP BY
    make, model
ORDER BY
    total_rentals DESC
LIMIT 10;
  
```

Resultados 1 X

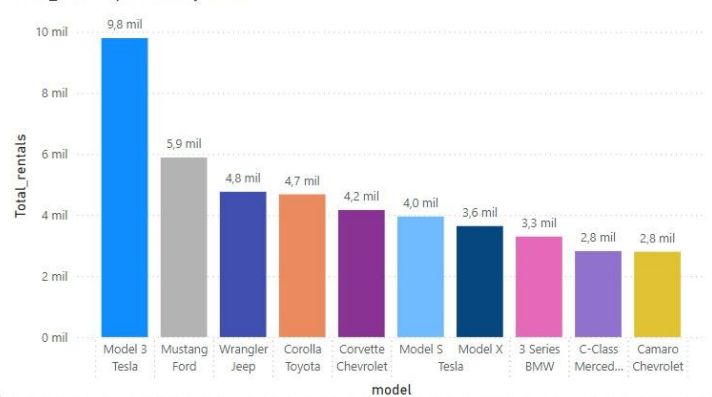
SELECT make AS brand, model, SUM(rentertripstaken) AS total_rentals

	A-z brand	A-z model	123 total_rentals
1	Tesla	Model 3	9.798
2	Ford	Mustang	5.885
3	Jeep	Wrangler	4.762
4	Toyota	Corolla	4.678
5	Chevrolet	Corvette	4.164
6	Tesla	Model S	3.953
7	Tesla	Model X	3.638
8	BMW	3 Series	3.294
9	Mercedes-Benz	C-Class	2.818
10	Chevrolet	Camaro	2.797

Total_rentals por brand y model



Total_rentals por brand y model



Esta consulta y estos gráficos muestran que los autos marca Tesla, con su modelo Model 3 es el auto más alquilado, y su modelo Model S es el sexto y el model X en séptimo lugar en la lista, siendo también la marca Tesla la marca más alquilada. El segundo modelo más alquilado es el Mustang de Ford. El tercer lugar se lo lleva jeep modelo es la Jeep Wrangler. El cuarto lugar es para Toyota con el Corola y el quinto Chevrolet con el Corvette.

d.- Mostrar por año, cuántos alquileres se hicieron, teniendo en cuenta automóviles fabricados desde 2010 a 2015

```
SELECT
    year,
    SUM(rentertripstaken) AS total_rentals
FROM
    car_rental_db.car_rental_analytics__year
WHERE
    vehicle_year BETWEEN 2010 AND 2015
GROUP BY
    year
ORDER BY
    year ASC;
ORDER BY year ASC;
=
```

e.- las 5 ciudades con más alquileres de vehículos ecológicos (fuelType híbrido o electrico)

```
SELECT
    city,
    SUM(rentertripstaken) AS total_rentals
FROM
    car_rental_analytics
WHERE
    LOWER(fueltype) IN ('hybrid', 'electric') -- Filtrar vehículos ecológicos
```

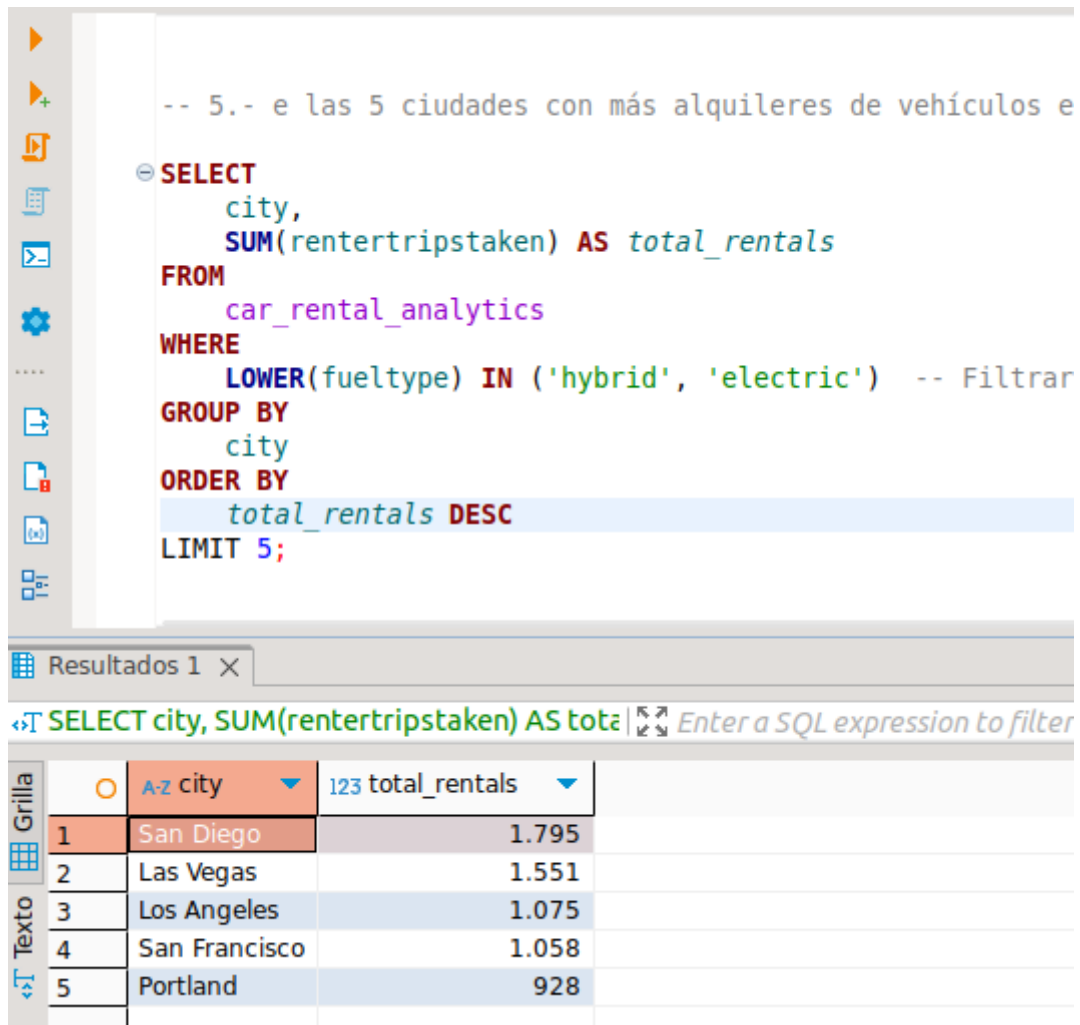

GROUP BY

city

ORDER BY

total_rentals **DESC**

LIMIT 5;



The screenshot shows a SQL IDE interface. The top pane contains a SQL query: `-- 5.- e las 5 ciudades con más alquileres de vehículos e`
`SELECT`
`city,`
`SUM(rentertripstaken) AS total_rentals`
`FROM`
`car_rental_analytics`
`WHERE`
`LOWER(fueltype) IN ('hybrid', 'electric') -- Filtrar`
`GROUP BY`
`city`
`ORDER BY`
`total_rentals DESC`
`LIMIT 5;`

The bottom pane shows the results in a table view. The table has two columns: 'city' and 'total_rentals'. The results are as follows:

	city	total_rentals
1	San Diego	1.795
2	Las Vegas	1.551
3	Los Angeles	1.075
4	San Francisco	1.058
5	Portland	928

f.- el promedio de reviews, segmentando por tipo de combustible

SELECT

LOWER(fueltype) **AS** fueltype,

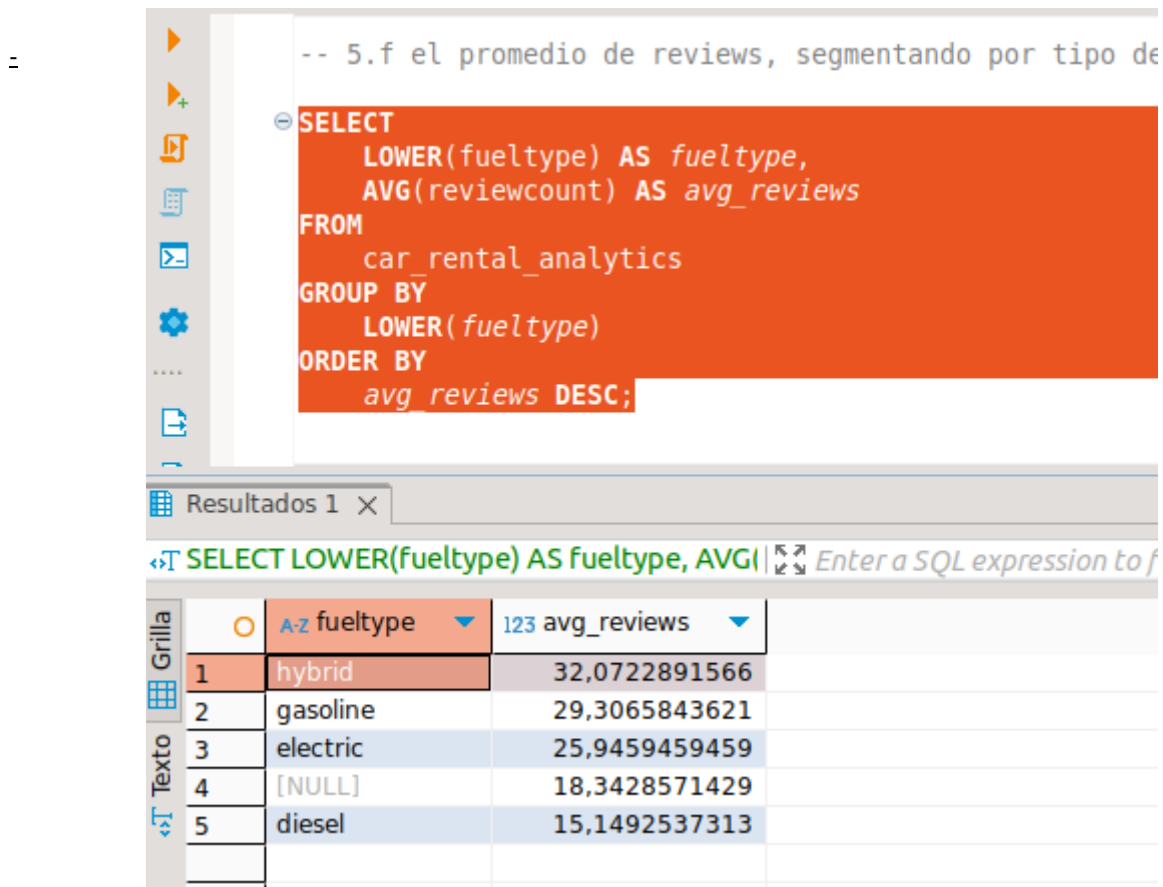
AVG(reviewcount) **AS** avg_reviews

FROM

car_rental_analytics


GROUP BY

LOWER(fueltype)
ORDER BY
 avg_reviews DESC;



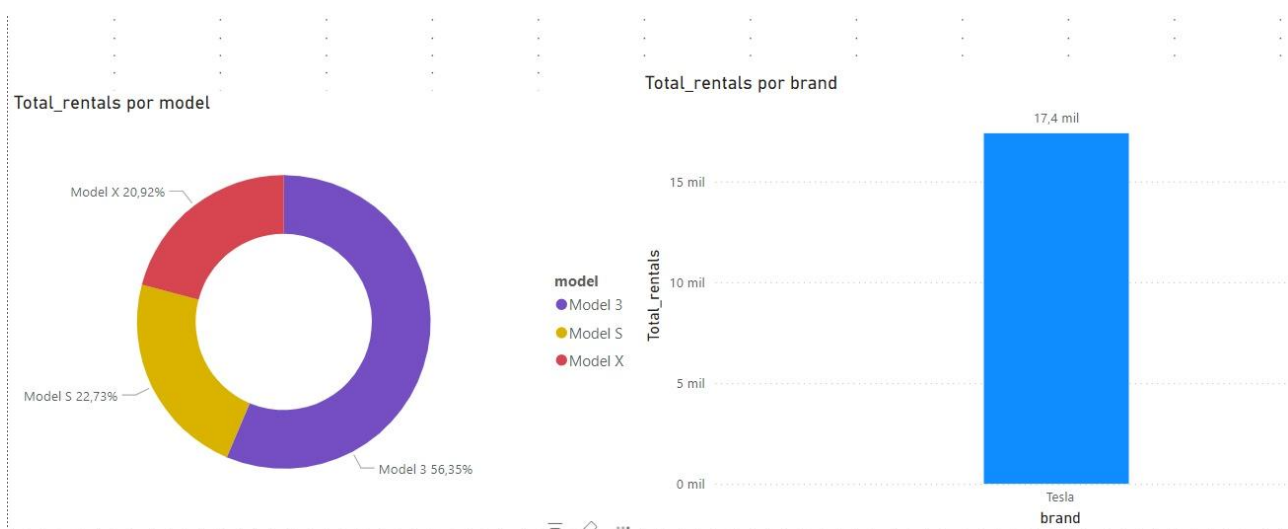
6.- Algunas conclusiones sobre este análisis:

A continuación podrán observar algunas gráficos adicionales para este análisis.



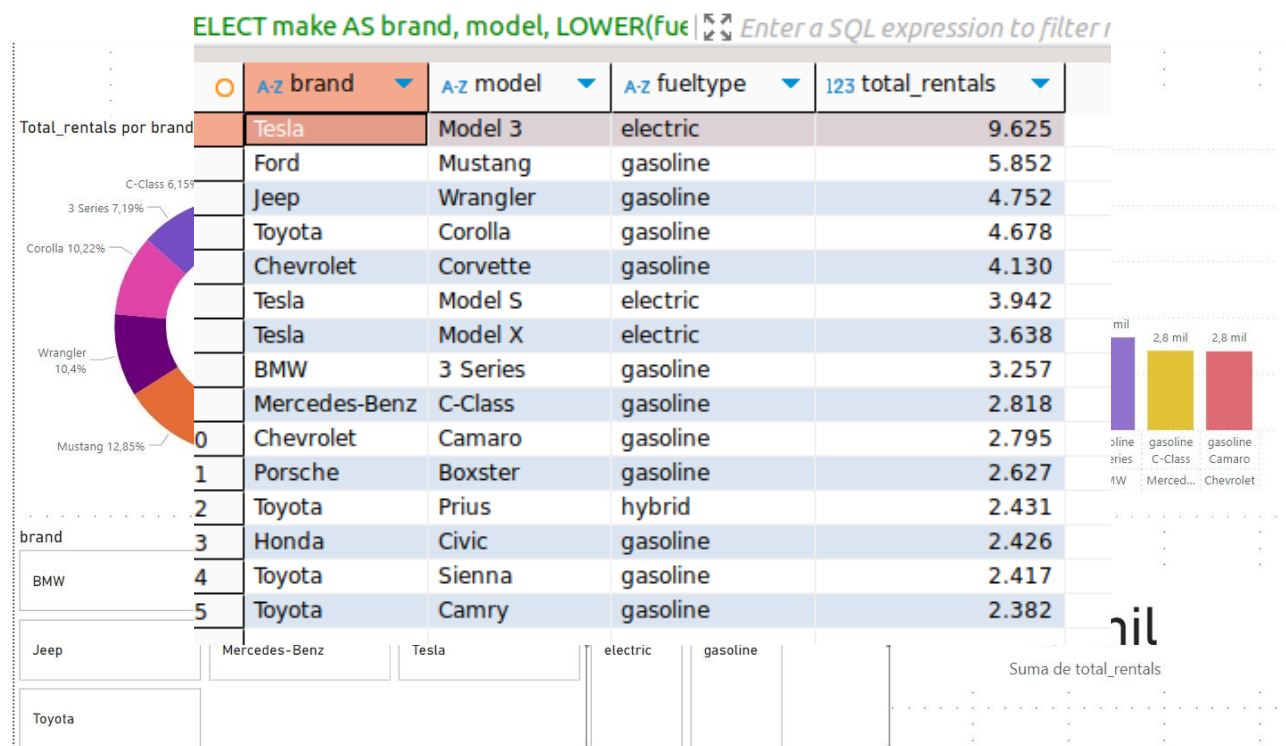
-Total de alquileres por marca

Este gráfico es el total de alquileres por marca y modelo, como ya hemos visto TESLA lleva la delantera de alquiler. -

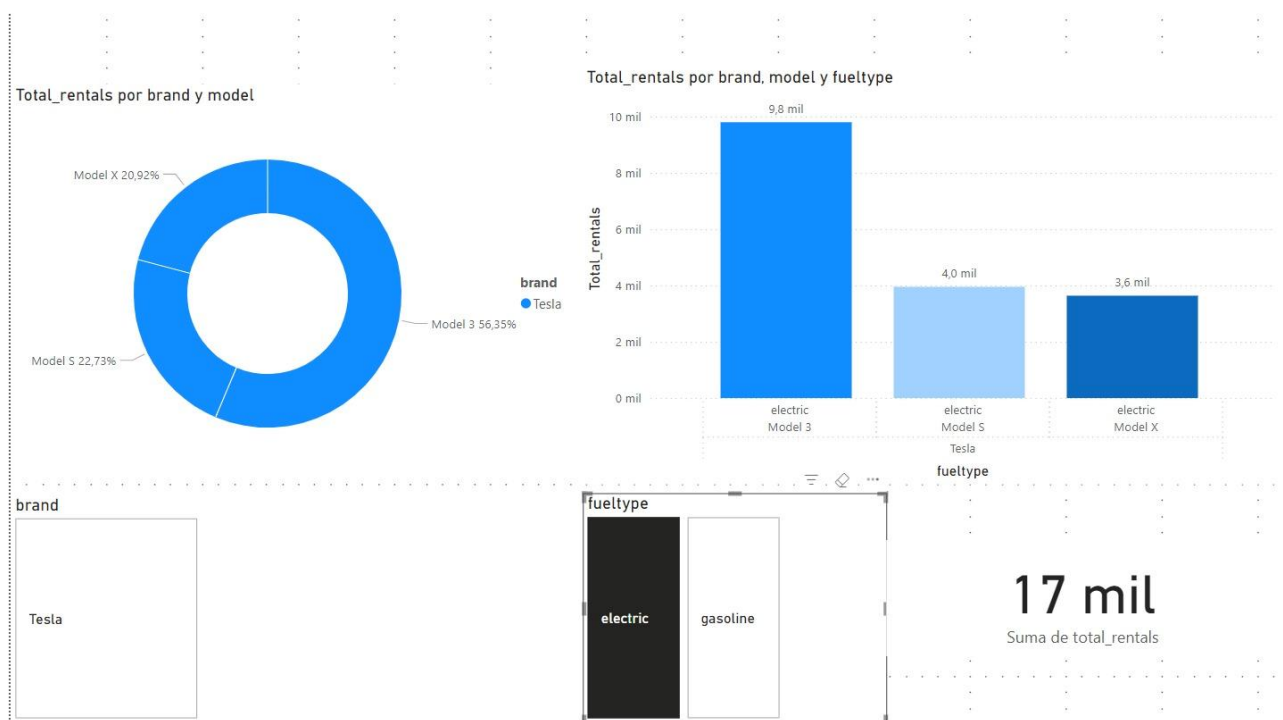


TESLA son un autos eléctricos, tiene 3 tipos de modelo, lleva a pensar que son para viajes no demasiados largos, máximo 600 km, ya que luego debe cargar las baterías, máximo tiempo de carga 1 hs. Otra ventaja que pueden tener los TESLA es su equipamiento tecnológico entre ellos, la posibilidad de conducción automática. Pero vemos otras marcas.

Sobre las 10 marcas más alquiladas vemos que Tesla está ala delantera quedando los híbridos en el puesto 12, como muestra esta consulta adicionales



Primeras 10 marcas alquiladas.



-Total de alquileres de autos eléctricos, Tesla cuenta con tres modelos de autos para alquilar, siendo el modelo Model 3 el más popular, seguido por el Model S y el X. Al ser los autos de Tesla los más alquilados, una conclusión podría ser que son para viajes relativamente corto, de 600 KM, para que es en promedio la autonomía de un Tesla.



Total alquileres autos a gasolina, el primero en la lista en el Mustang de Ford, seguido por el Jeep Wrangler y el Toyota Corolla. La oferta de autos a gasolina sigue siendo más amplia que la eléctrica y seguramente utilizados para viajes más largos.

Con respecto a los reviews podemos comentar

Los vehículos híbridos (hybrid) tienen el mayor promedio de reviews (32.07) aunque no están en las primeras marcas alquiladas:

- Esto sugiere que los usuarios valoran más los vehículos híbridos, posiblemente debido a su eficiencia de combustible o comodidad, ya que no necesitan cargar el auto.
- Podría ser un indicador de alta satisfacción con este tipo de vehículos.

Los vehículos de gasolina (gasoline) están en segundo lugar (29.31) y son los segundos **más** alquilados:

- Aunque no tan valorados como los híbridos, los vehículos de gasolina mantienen un promedio alto, lo que podría indicar que siguen siendo populares y bien aceptados.

Los vehículos eléctricos (electric) tienen un promedio intermedio (25.95) siendo los primeros entre las 10 marcas **más** alquiladas:

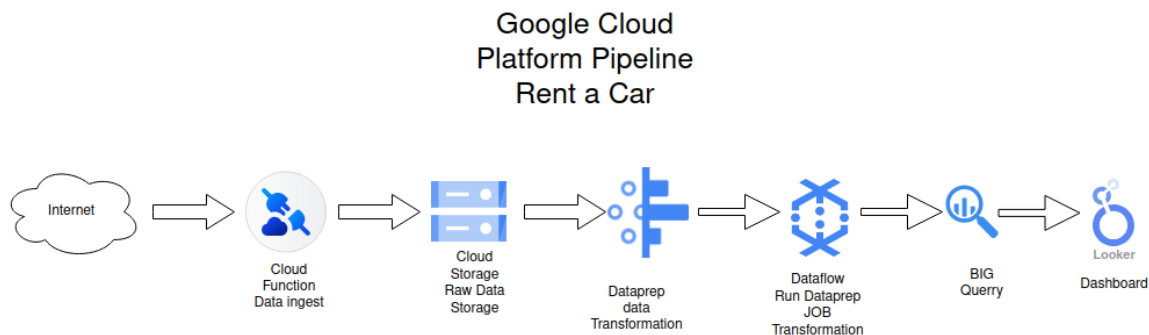
- Aunque los eléctricos son ecológicos y tienen ventajas, el promedio ligeramente más bajo podría reflejar preocupaciones sobre autonomía, infraestructura de carga, o precio.

Los vehículos diésel (diesel) tienen el promedio más bajo (15.15):

- Esto podría indicar una percepción negativa de los vehículos diésel, quizás debido a su impacto ambiental o costos operativos más altos.

Con estos breves análisis podemos llegar a la conclusión que la empresa es una empresa en crecimiento, adaptándose al mercado con la incorporación de nuevos productos e incorporando tecnología a la empresa, con más de 10 marcas de vehículos en su oferta desde auto de alta tecnología hasta un clásico como el Mustang. Con presencia en la mayoría de estados y principales ciudades de Estados Unidos.

Arquitectura Alternativa



Para realizar el análisis de de estos dataset podemos utilizar una infraestructura Cloud para dotar al dicho trabajo y futuros análisis de escalabilidad, gobernanza de datos y seguridad.

La arquitectura propuesta es sobre Google Cloud Platform (GCP). Los pasos a reaizar, son los siguientes:

- 1.- Cloud Function: en esta etapa a través de una función que ingesta, por ejemplo a través de un scrip PYSPARK, los datos desde intenet.
- 2.- Cloud Storage: los datos ingestados coo raw data son guardados en Cloud Storage, el almacenamiento masivo de GCP, donde se realiza el storage de los datos para luego ser utilizados en las etapas de ETL.
- 3.- Dataprep: para realizar el ETL de los datos de forma dinámica, permitiendo ganar tiempo en la transformación y análisis de los datos. Una vez realizada la transformación según la estrategia del negocio, los datos se guardan en una tabla de BigQuery.

4.- Big Query, ya con los datos transformados en BQ podemos realizar las consultas necesarias para poder obtener información relevante del negocio. Se pueden generar distintas vistas y ser graficadas a posteriori.

5.- Looker u PowerBI: son herramientas de visualización que se conectan con Big Query y nos permiten realizar Dashboard sobre los diferentes análisis de datos que realizamos en BigQuery. Estos gráficos son interactivos y permiten tener una imagen relacional del negocio.